



UNIVERSIDADE DE FORTALEZA
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM ENGENHARIA ELÉTRICA

UTILIZAÇÃO DE DEEP LEARNING PARA MODELAGEM DE UM CONTROLADOR NEURAL DE VELOCIDADE DE UM MOTOR CC

ARTUR GOMES BARRETO

ORIENTADOR: PROF. ME. ANTÔNIO ROBERTO LINS DE MACÊDO

Sumário

- Contextualização
- Objetivos
- Método
- Estudo de Caso
- Resultados
- Conclusões
- Trabalhos Futuros
- Referências

Contextualização

Aplicações das RNAs (ABIODUN et al., 2018):

- Classificação de dados;
- Agrupamento de dados semelhantes (clustering);
- Reconhecimento de padrões;
- Predição de valores futuros.

Contextualização

Aplicações interessantes das RNAs:


- Detecção de falhas em sistemas de distribuição de energia elétrica (WANG *et al.*, 2019);
- Visão computacional para processamento de imagens (CHO; TAI; KWEON, 2019);
- Detecção de falhas em motores elétricos (RAMALHO *et al.*, 2014)
- Controle e Automação;
 - Controle da turbina eólica proposto (MAHMOUD, 2017);
 - Controle de velocidade de um motor CC (ABRAHAM *et al.* 2018);
 - Substituição de um controlador PID por um controlador neural para um motor CC (CHEON *et. al*, 2015).

Objetivos

- O objetivo geral desse trabalho é utilizar uma arquitetura de *deep learning* chamado de *Deep Belief Network* (DBN) para modelar e treinar uma RNA que seja capaz de imitar o comportamento de um controlador PID e assim controlar a velocidade do motor CC. Esta RNA foi denominada de Controlador Neural (CN).
- Os objetivos específicos são:
 - Estudo bibliográfico sobre *Deep Learning*, controladores PID e motores CC
 - Modelar e simular um motor CC e um controlador PID para obter os dados de treinamento
 - Modelar a RNA
 - Realizar uma análise comparativa entre o CN modelado e o controlador PID

Método

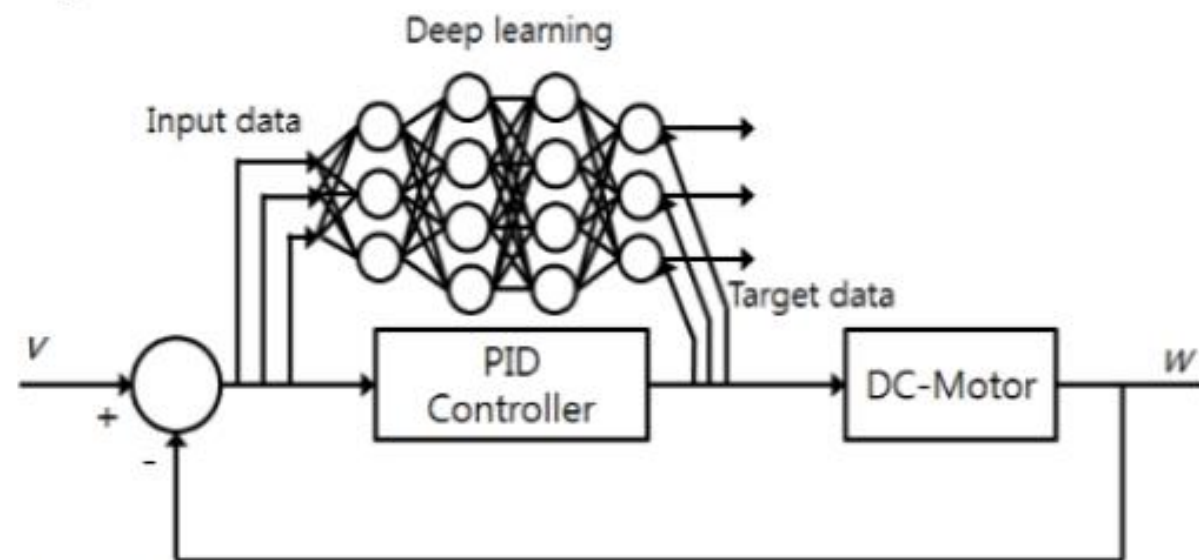
Figura 19 – Simulação do Controlador PID e do Motor CC



Fonte: Cheon *et al.*, 2015.

Método

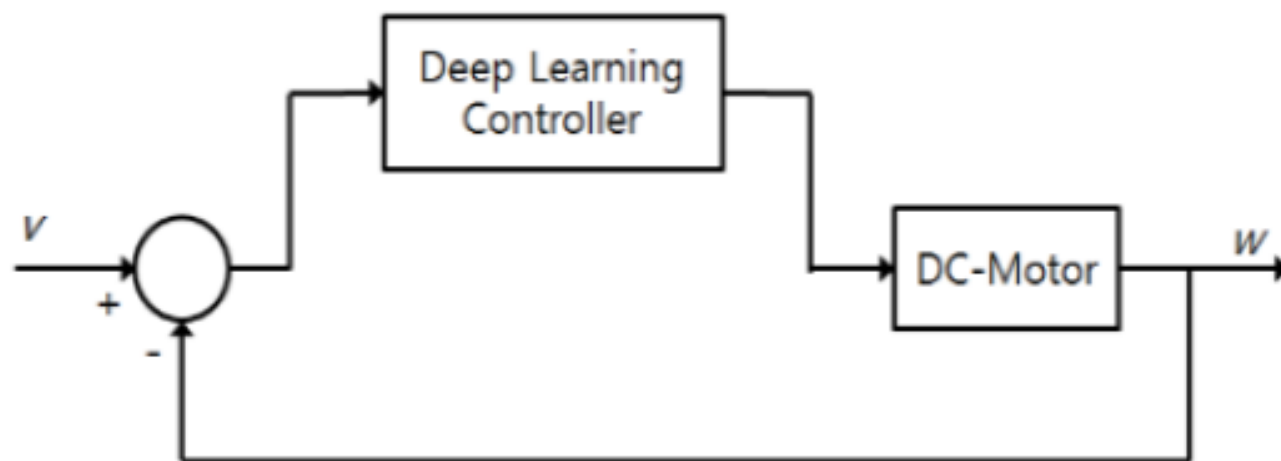
Figura 20 – Treinamento do CN



Fonte: Cheon *et al.*, 2015.

Método

Figura 21 – Substituição do Controlador PID pelo CN

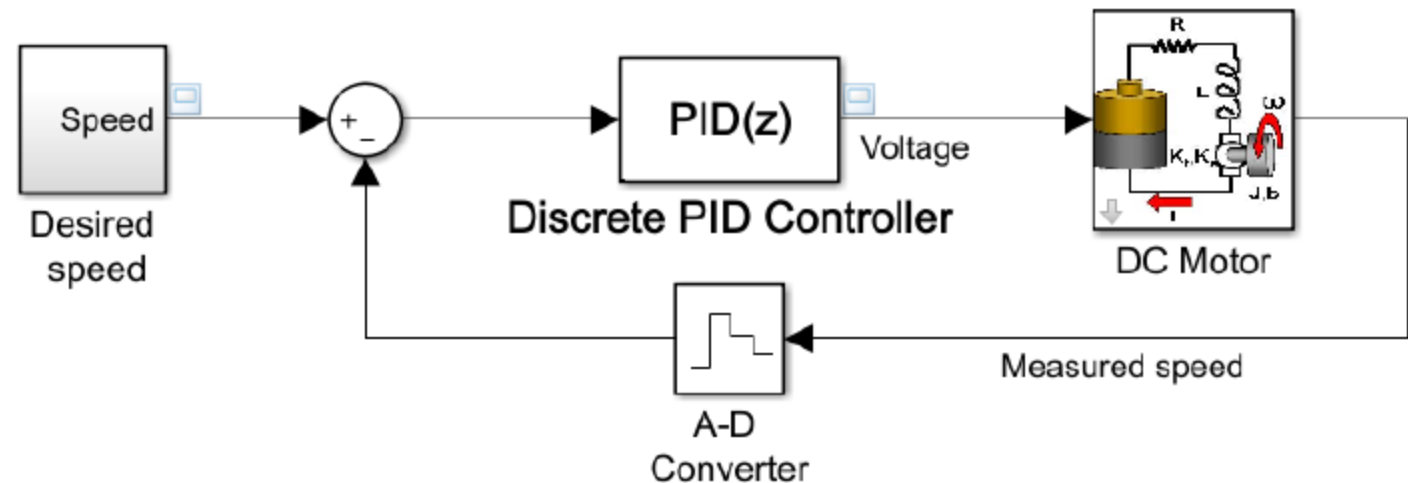


Fonte: Cheon *et al.*, 2015.

Estudo de Caso – Simulação do Sistema

- Tempo entre 60 e 600 segundos
- Passo no tempo das simulações foi de 0,02 segundo.
- As grandezas observadas nessas simulações foram:
 - A velocidade desejada
 - A velocidade medida do motor CC
 - O sinal de saída do controlador PID

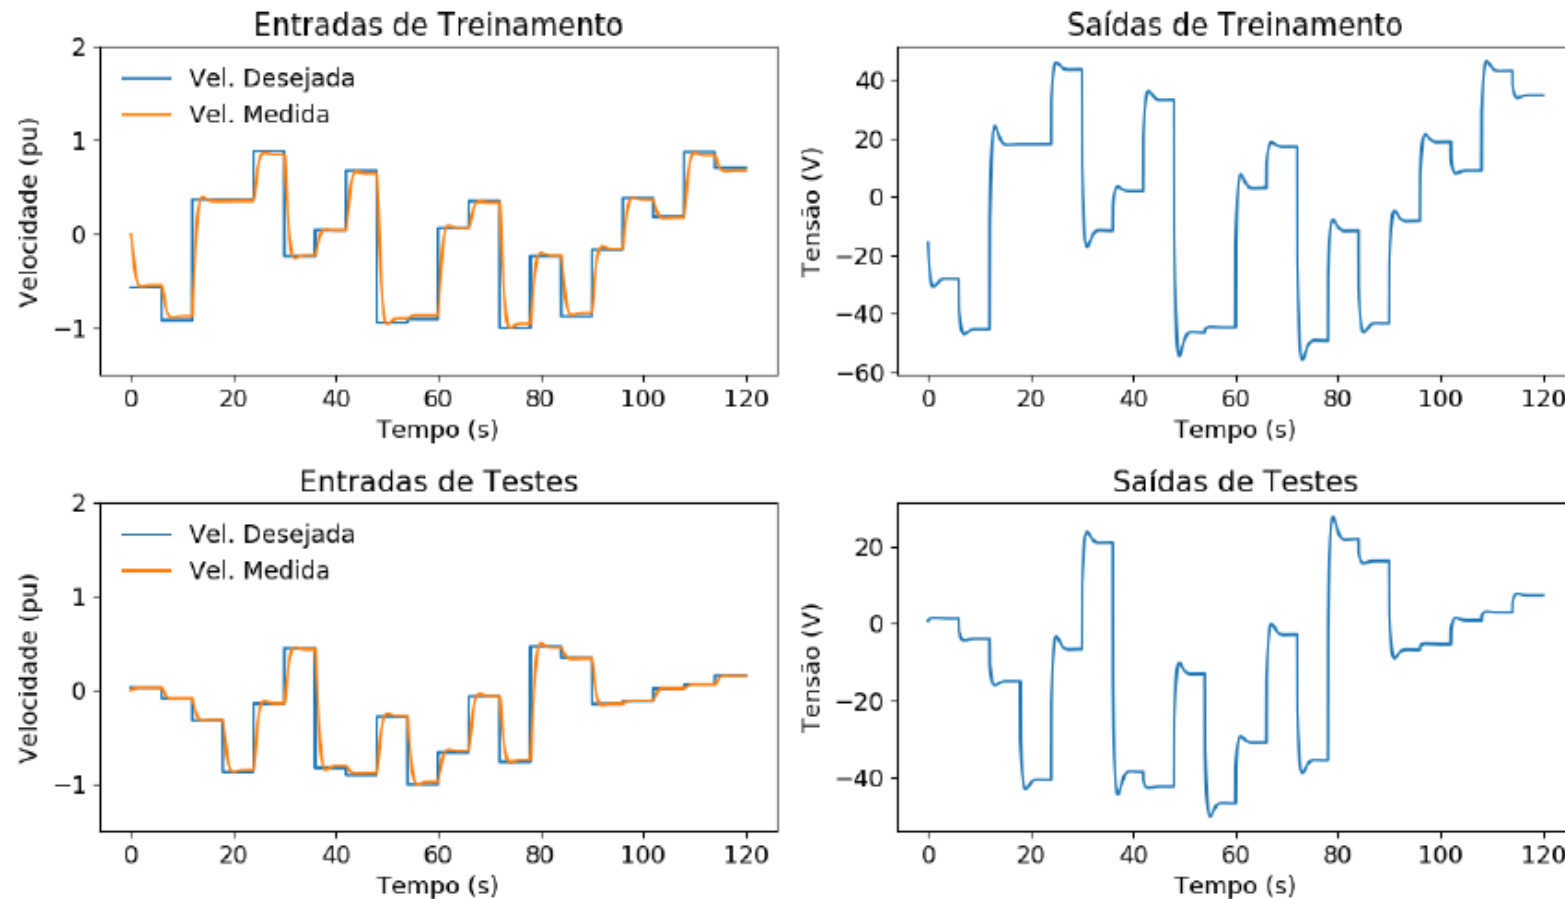
Figura 24 – Sistema do Motor CC e Controlador PID



Fonte: Elaborado pelo autor.

Estudo de Caso – Dados de Treinamento

Gráfico 6 – Dados de Treinamento e Teste da RNA



Estudo de Caso – Ajuste do Modelo


- Para determinação dos hiperparâmetros do modelo final, testamos aproximadamente 2500 topologias diferentes. Em cada um desses testes, variou-se um dos hiperparâmetro por vez, mantendo os outros constantes.
- Os hiperparâmetros variados e testados foram:
 - O número de camadas;
 - A quantidade de neurônios por camada;
 - O número de épocas de treinamento da etapa não-supervisionada (pré-treino);
 - O número de iterações de *backpropagation* da etapa supervisionada (ajuste-fino);
 - O tamanho do lote de treinamento;
 - A quantidade de dados utilizados no treinamento;
 - As taxas de *Dropout*.

Estudo de Caso – Ajuste do Modelo

- Em cada teste, calculou-se o MSE (*Mean Square Error* ou o Erro Quadrático Médio) das saídas com o conjunto de dados de teste.
- Foram realizados, ao todo, 16 seções de testes dos hiperparâmetros. Cada uma dessas seções testavam um subconjunto de possibilidades para esses hiperparâmetros.
- Intel Core I7-3610QM de 2,30 GHz de 8 núcleos, 8 GB de memória RAM e placa de vídeo Nvidia GeForce GT 630M de 2 GB de memória dedicada.
- Primeiros testes duraram até 32 horas ininterruptas para serem concluídas.
- Últimos testes levaram aproximadamente 1 hora.

Estudo de Caso – Ajuste do Modelo

Gráfico 11 – Erro Quadrático Médio em Função da Topologia (E)



Fonte: Elaborado pelo autor.

Estudo de Caso – Modelo Final


Tabela 8 – Hiperparâmetros do Modelo do CN

Hiperparâmetros	Valor
Número de Camadas	3
Neurônios por Camada	90
Épocas de treinamento da etapa não-supervisionada	3
Iterações de <i>backpropagation</i> da etapa supervisionada	50
Quantidade de dados utilizados no treinamento	120s
Tamanho do Lote de Treinamento	16
<i>Dropout</i>	0%
Taxa de aprendizagem da etapa não-supervisionada	0,01
Taxa de aprendizagem da etapa supervisionada	0,01
Função de ativação	Sigmóide

Fonte: Elaborado pelo autor.

Resultados – Entrada Degrau

Gráfico 20 – Respostas do CN e PID a Entrada Degrau

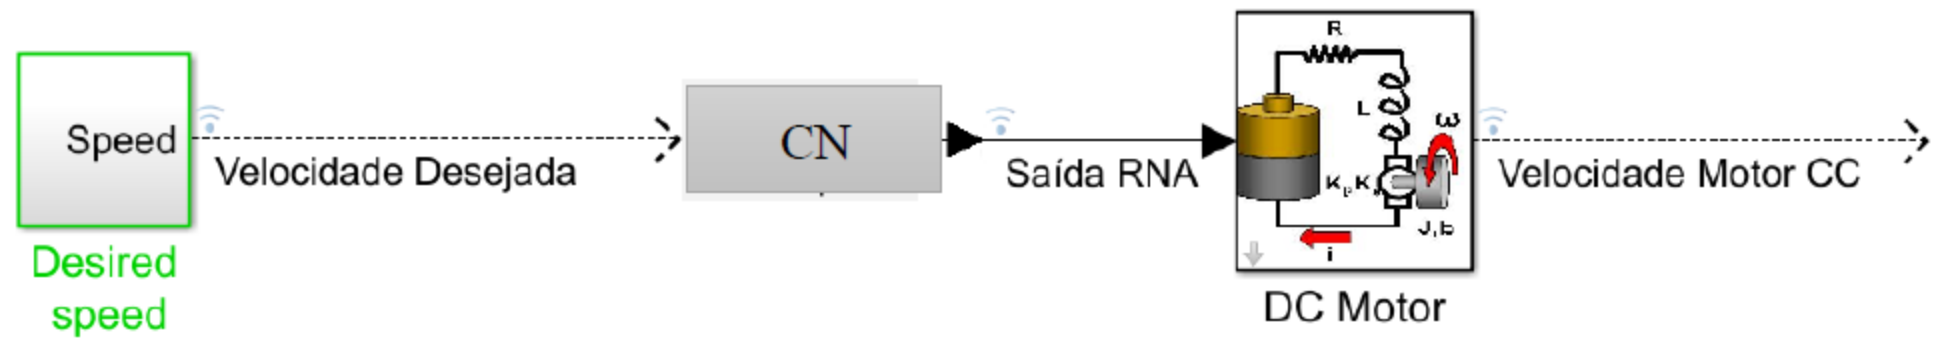


Fonte: Elaborado pelo autor.

- MSE de 0,0778 V²
- Erro Estacionário de 0,1774 V

Resultados – Entrada Degrau

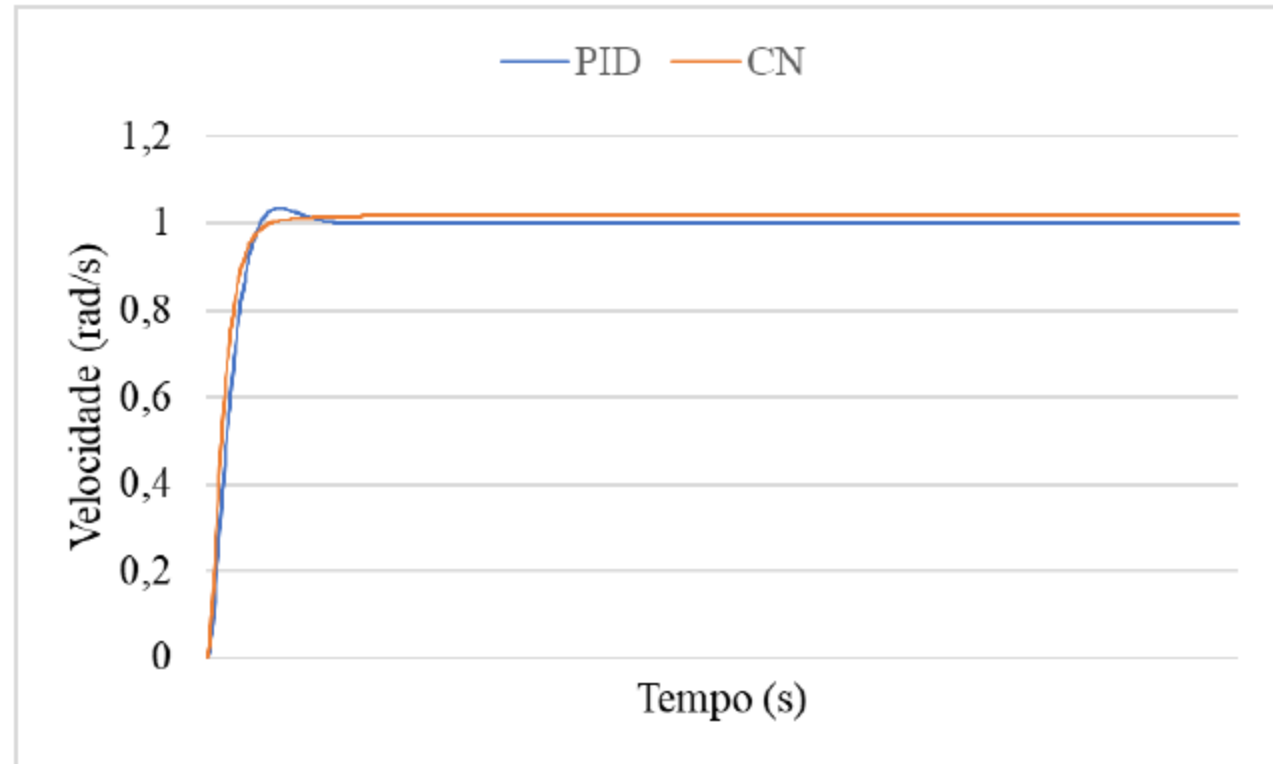
Figura 25 – *Toolbox* Alterada para o que CN Controle o Motor CC



Fonte: Elaborado pelo autor.

Resultados – Entrada Degrau

Gráfico 21 – Curvas de Velocidade do PID e CN – Entrada Degrau



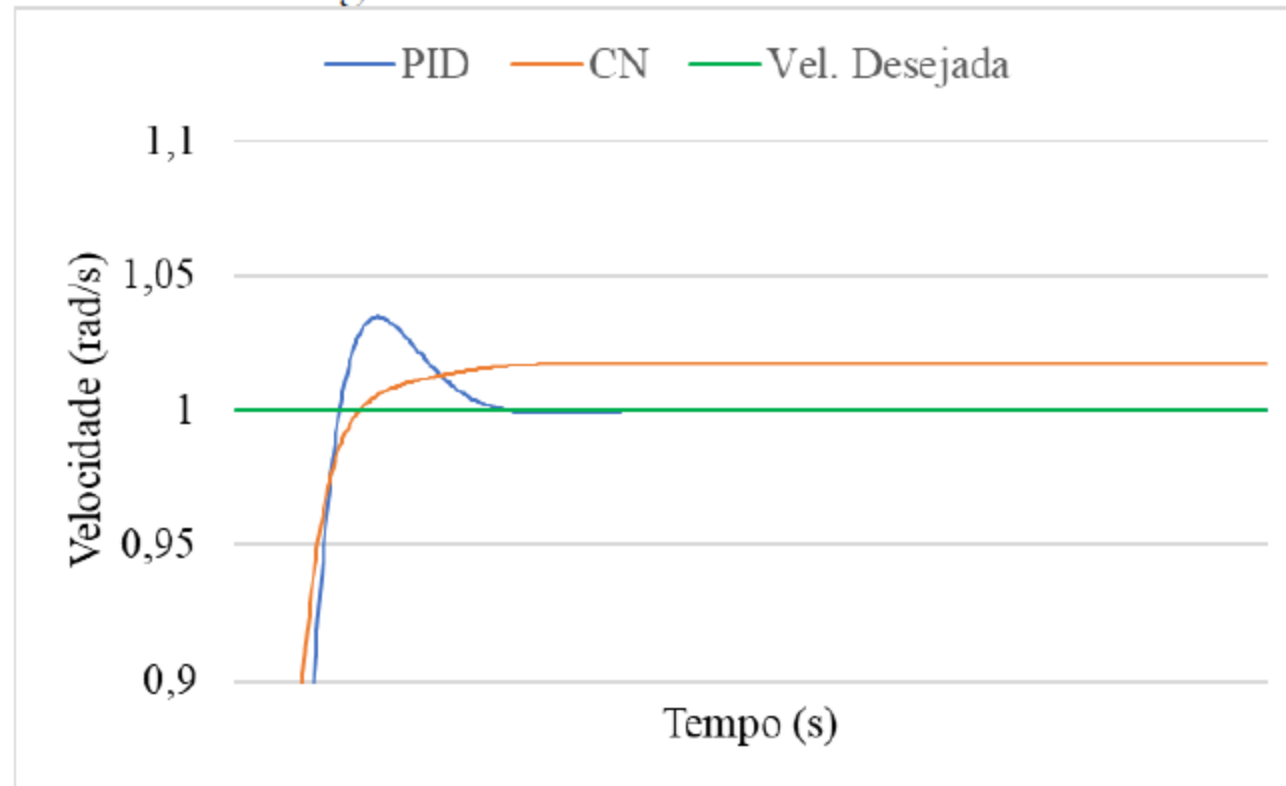
➤ MSE de 0,0004 rad^2/s^2

➤ Erro Estacionário de 0,0177 rad/s

Fonte: Elaborado pelo autor.

Resultados – Entrada Degrau

Gráfico 22 – Região de Interesse das Curvas de Velocidade – Entrada Degrau



Fonte: Elaborado pelo autor.

Resultados – Entrada Degrau

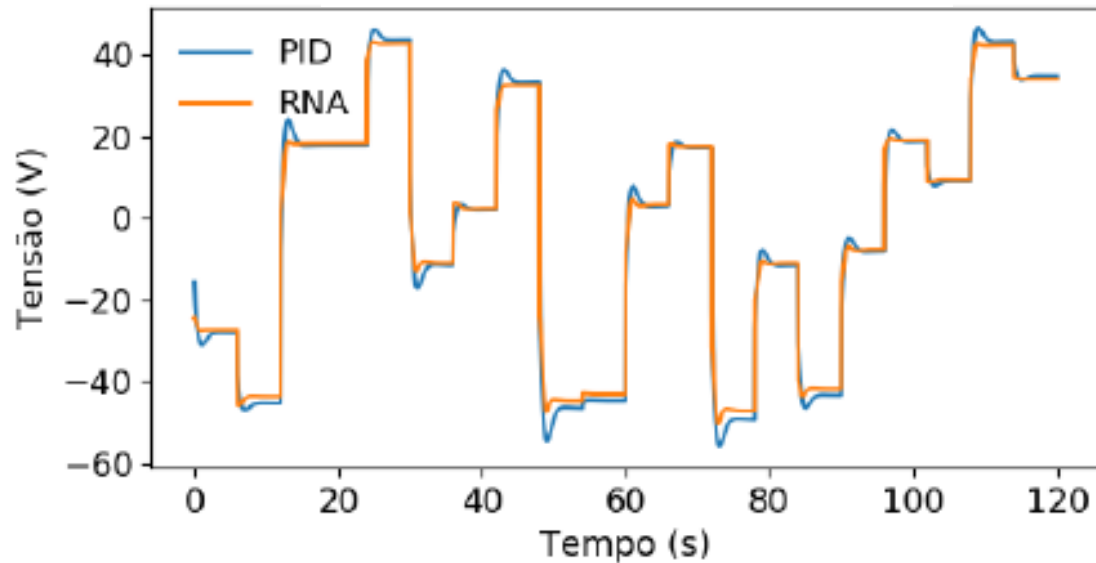
Tabela 9 – Parâmetros da Resposta Transitória e de Regime Permanente do Sistema

	t_d (s)	t_r (s)	t_p (s)	M_p (%)	t_s (s)	E_s (%)
PID	0,56	1,54	2,06	3,47	2,74	0
CN	0,40	1,82	5,62	1,78	1,44	-1,74
Δ	-28,57%	18,18%	172,82%	-48,70%	-47,44%	∞


Fonte: Elaborado pelo autor.

Resultados – Entrada Complexa

Dados de Treinamento



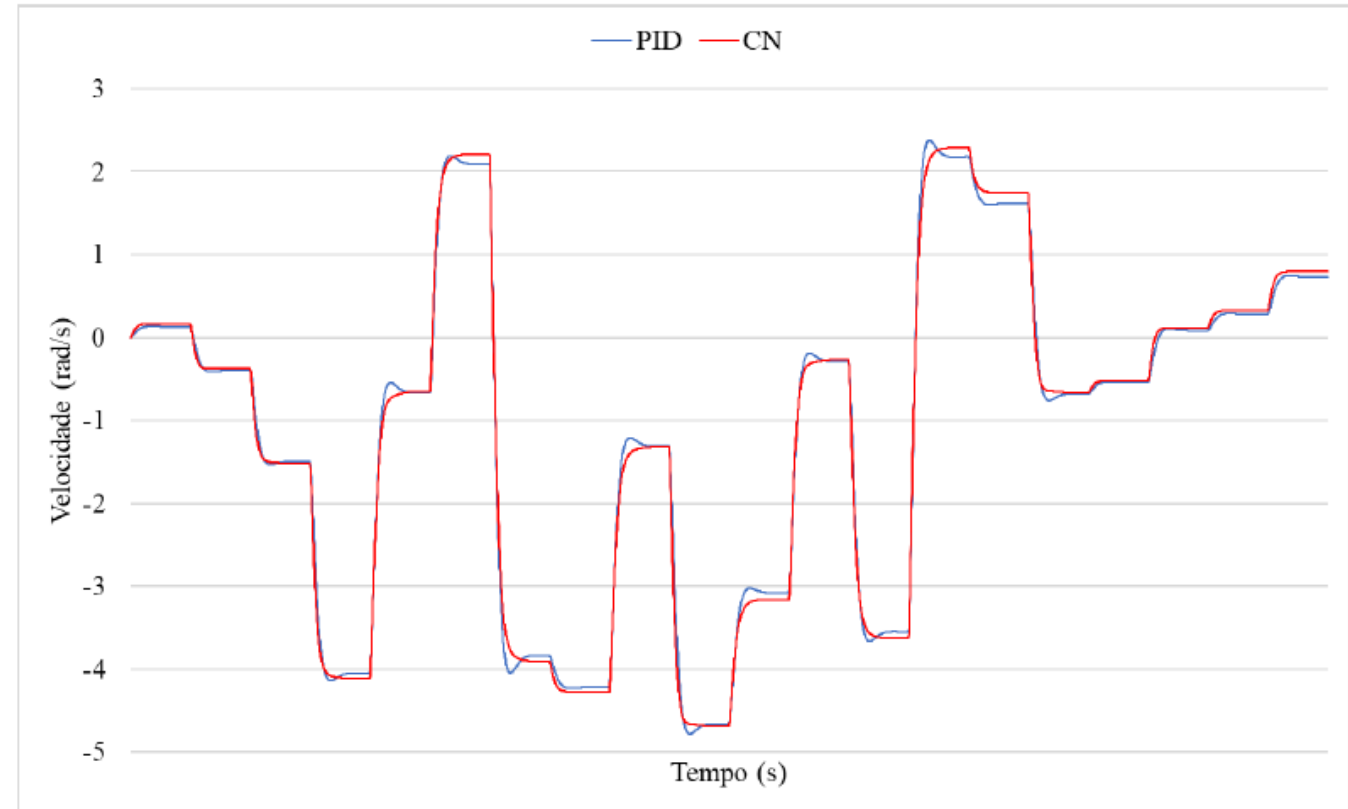
Dados de Teste



➤ MSE de 2,1883 V

Resultados – Entrada Complexa

Gráfico 24 – Curvas de Velocidades do Controlador PID e CN – Dados de Teste



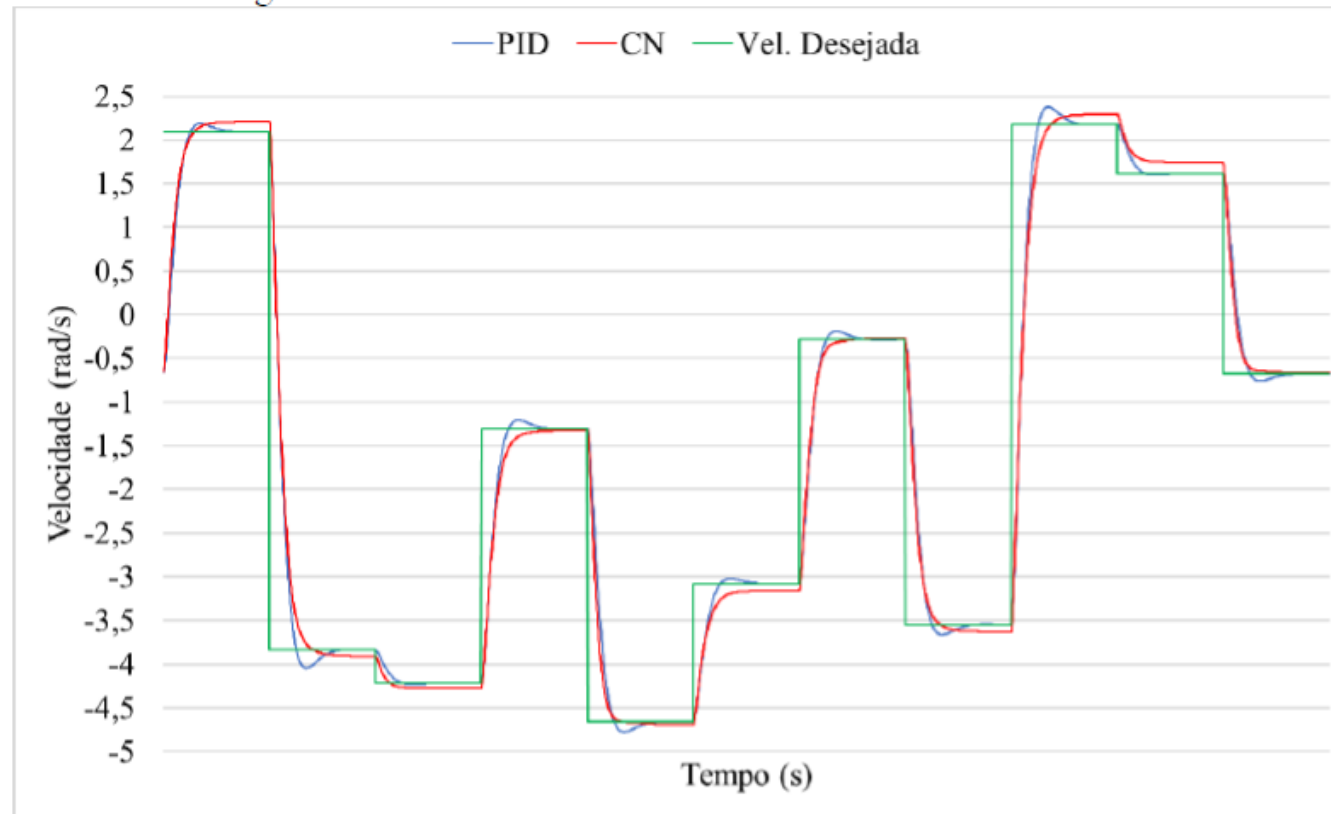
Fonte: Elaborado pelo autor.

➤ MSE de 0,0097 rad^2/s^2

➤ Diferenças em transitórios

Resultados – Entrada Complexa

Gráfico 25 – Região de Interesse das Curvas de Velocidade – Dados de Teste



Fonte: Elaborado pelo autor.

Conclusões

- É possível afirmar que o CN é mais lento na busca da velocidade desejada no período transitório.
- Além disso, possui um erro estacionário maior.
- Contudo, sua resposta alcança uma estabilidade mais rapidamente
- Possui um sobressinal menor, em comparação ao controlador PID.
- Os perfis de velocidade gerados pelo CN e pelo PID são bastante próximos, existindo um erro quadrático médio de apenas $0,0097 \text{ rad}^2/\text{s}^2$ entre eles.

Conclusões

- A referência utilizada para determinar a qualidade desse resultado e definir qual solução é superior é determinada pelo processo a ser controlado pelo motor.
- Como abstraímos esse requisito, ou seja, não temos uma aplicação em mente para esse motor CC, não temos condições de aprofundar nossas análises e afirmar se o CN é uma solução superior ao controlador PID.
- O que podemos afirmar, sem sombra de dúvidas, é que os resultados encontrados comprovam que é possível utilizar *Deep Learning* e montar uma RNA profunda, utilizando uma arquitetura *Deep Belief Network* com *backpropagation*, capaz de aprender a se comportar como um controlador PID e controlar a velocidade de um motor CC.

Trabalhos Futuros

- Utilizar um motor CC real e montar um *hardware* para coletar os dados de treinamento e teste.
- Analisar a capacidade das Redes Neurais Recorrentes para resolver esse problema de controle.
Acreditamos que essa arquitetura resolva bem o problema estudado devido à natureza temporal e sequencial do comportamento da velocidade do motor CC – justamente o tipo de fenômeno que as Redes Neurais Recorrentes se propõem a modelar.

Trabalhos Futuros

- Utilizar um método de otimização para os hiperparâmetros da rede como a otimização Bayesiana, em vez do método empírico que utilizamos.
- Criação de conjuntos de dados de treino e teste que incluam mais possibilidades de variação entre dois estados de velocidade consecutivos.
- Realizar mais testes para validar o CN.

Referências

ABIODUN, O. I. *et al.* State-of-the-art in artificial neural network applications: A survey. **Heliyon**, v. 4, n. 11, p. e00938, 2018.

ABRAHAM, J.; SHRIVASTAVA, S. Dc Motor Speed Control Using Machine Learning Algorithm. **International Journal of Engineering Research & Technology**, v. 7, n. 04, p. 456–470, 2018.

ALEXANDER, C. K.; SADIKU, M. **Fundamentos de Circuitos Elétricos**. 5a ed. Porto Alegre: AMGH, 2013.

ANG, K. H. *et al.* PID control system analysis and design. **IEEE Control Systems**, v. 26, n. 1, p. 32–41, 2006.

APRUZZESE, G. *et al.* On the effectiveness of machine and deep learning for cyber security. **International Conference on Cyber Conflict, CYCON**, v. 2018- May, p. 371–389, 2018.

AREL, I.; ROSE, D. C.; KARNOWSKI, T. P. Deep Machine Learning - A New Frontier in AI Research. **IEEE Computational Intelligence Magazine**, n. November, p. 13–18, 2010.

Referências

ARNOLD, L. *et al.* An introduction to deep learning. **ESANN 2011 proceedings, 19th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning**, n. April, p. 477–488, 2010.

ARUNAVA. **Towards Data Science**. Disponível em: <<https://towardsdatascience.com/derivative-of-the-sigmoid-function-536880cf918e>>. Acesso em: 4 nov. 2019.

BRAGA, ANTÔNIO; CARVALHO, ANDRÉ; LUDERMIR, T. **Redes Neurais Artificiais - Teoria e Aplicações**. 2. ed. Rio de Janeiro: LTC, 2007.

BUP, A. **A Python implementation of Deep Belief Networks built upon NumPy and TensorFlow with scikit-learn compatibility**. Disponível em: <<https://github.com/albertbup/deep-belief-network>>. Acesso em: 13 set. 2019.

CHAPMAN, S. J. **Fundamentos de Máquinas Elétricas**. 5. ed. Porto Alegre: AMGH, 2013.

CHEN, P. *et al.* Control strategy of speed servo systems based on deep reinforcement learning. **Algorithms**, v. 11, n. 5, 2018.

Referências

CHEON, K. *et al.* On Replacing PID Controller with Deep Learning Controller for DC Motor System. **Journal of Automation and Control Engineering**, v. 3, n. 6, p. 452–456, 2015.

CHO, D.; TAI, Y. W.; KWEON, I. S. Deep Convolutional Neural Network for Natural Image Matting Using Initial Alpha Mattes. **IEEE Transactions on Image Processing**, v. 28, n. 3, p. 1054–1067, 2019.

CHOLLET, F. **Keras**. Disponível em: <<https://keras.io/>>. Acesso em: 13 set. 2019.

CHOLLET, F. **Deep Learning with Python und Keras: Das Praxis-Handbuch vom Entwickler der Keras-Bibliothek**. 2. ed. Shelter Island: Manning Publications Co., 2018.

DENG, L. Three classes of deep learning architectures and their applications: a tutorial survey. **APSIPA transactions on signal and information processing**, 2012.

FITZGERALD, A. E.; KINGSLEY, C.; UMANS, S. D. **Máquinas Elétricas**. 7a ed. Porto Alegre: AMGH, 2014.

Referências

FLEMMING, D. M.; GONÇALVES, M. B. **Cálculo A: Funções, Limite, Derivação e Integração**. 6. ed. Porto Alegre: Pearson, 2006.

GRAF, J. **PID Control Fundamentals**. 1a ed. Scotts Valley: CreateSpace, 2016.

HAYKIN, S. **Redes Neurais: Princípios e Prática**. 2. ed. Porto Alegre: Bookman, 2003.

HAYKIN, S.; VEEN, B. VAN. **Sinais e Sistemas**. 1a ed. Porto Alegre: Bookman, 2001.

HINTON, G.; OSINDERO, S.; TEH, Y.-W. A fast learning algorithm for deep belief nets. **Neural Computation**, v. 18, n. 7, p. 1527–1554, 2006.

HODGKING, A. L.; HUXLEY, A. F. A quantitative description of membrane current and its application to conduction and excitation in nerve. **Journal of Physiology**, v. 117, p. 500–544, 1952.

Referências

HONDA, F. **Motores de Corrente Contínua: Guia rápido para uma especificação precisa**. 1a ed. São Paulo: Siemens, 2006.

HUA, Y.; GUO, J.; ZHAO, H. Deep Belief Networks and deep learning. **Proceedings of 2015 International Conference on Intelligent Computing and Internet of Things, ICIT 2015**, 2015.

JOHNSON, M. A.; MORADI, M. H. (EDS.). **PID Control: New Identification and Design Methods**. 1a ed. New York: Springer Publishing, 2005.

KOVÁCS, Z. **Redes Neurais Artificiais - Fundamentos e Aplicações**. 4. ed. São Paulo: Livraria da Física, 2002.

LATHI, B. P. **Sinais e Sistemas Lineares**. 2a ed. Porto Alegre: Bookman, 2007.

LAZZERI, S. G.; HELLER, R. An intelligent consultant system for chess. **Computers and Education**, v. 27, n. 3–4, p. 181–196, 1996.

Referências

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LIU, W. *et al.* A survey of deep neural network architectures and their applications. **Neurocomputing**, v. 234, n. October 2016, p. 11–26, 2017.

MA, J. *et al.* Improving air quality prediction accuracy at larger temporal resolutions using deep learning and transfer learning techniques. **Atmospheric Environment**, v. 214, n. April, p. 116885, 2019.

MAHMOUD, T. K.; DONG, Z. Y.; MA, J. A Developed Integrated Scheme Based Approach for Wind Turbine Intelligent Control. **IEEE Transactions on Sustainable Energy**, v. 8, n. 3, p. 927–937, 2017.

MAIER, A. *et al.* A gentle introduction to deep learning in medical image processing. **Zeitschrift fur Medizinische Physik**, v. 29, n. 2, p. 86–101, 2019.

MATHWORKS. **MATLAB**. Disponível em: <<https://www.mathworks.com/products/matlab.html>>. Acesso em: 13 set. 2019.

Referências

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The bulletin of mathematical biology**, v. 5, n. 4, p. 115–133, 1943.

MEHDY, M. M. *et al.* Artificial neural networks in image processing for early detection of breast cancer. **Computational and Mathematical Methods in Medicine**, v. 2017, 2017.

MITCHELL, T. M. **Machine Learning**. 1. ed. New York: McGraw-Hill, 1997.

MOE, S.; RUSTAD, A. M.; HANSSEN, K. G. Machine Learning in Control Systems: An Overview of the State of the Art. **SGAI-AI 2018**, v. 11311, p. 250–265, 2018.

MOHAMMADI, M. *et al.* Deep learning for IoT big data and streaming analytics: A survey. **IEEE Communications Surveys and Tutorials**, v. 20, n. 4, p. 2923–2960, 2018.

NISE, N. S. **Engenharia de Sistemas de Controle**. 6a ed. Rio de Janeiro: LTC, 2012.

Referências

OGATA, K. **Engenharia de Controle Moderno**. 5a ed. São Paulo: Pearson Prentice Hall, 2010.

ROSSUM, G. VAN. **Python Organization**. Disponível em: <<https://www.python.org/about/>>. Acesso em: 13 set. 2019.

SARIYILDIZ, E.; YU, H.; OHNISHI, K. A practical tuning method for the robust PID controller with velocity feed-back. **Machines**, v. 3, n. 3, p. 208–222, 2015.

SILVA, IVAN; SPATTI, DANILO; FLAUZINO, R. **Redes Neurais Artificiais**. 2. ed. São Paulo: Artliber Editora Ltda., 2016.

SILVA, E. L.; MENEZES, E. M. **Metodologia da pesquisa e elaboração de dissertação**. 4. ed. Florianópolis: Universidade Federal de Santa Catarina, 2005.

SMOLENSKY, P. Information Processing in Dynamical Systems: Foundations of Harmony Theory. In: RUMELHART, D. E.; MCCLELLAND, J. L. (Eds.). . **Parallel Distributed Processing: Explorations in the Microstructure of Cognition**. 1. ed. Cambridge: MIT Press, 1986. p. 194–281.

Referências

STEWART, J. **Cálculo - Volume 1**. 6. ed. São Paulo: Cengage, 2009a.

STEWART, J. **Cálculo - Volume 2**. 6. ed. São Paulo: Cengage, 2009b.

TAI, L. *et al.* A Survey of Deep Network Solutions for Learning Control in Robotics: From Reinforcement to Imitation. **Journal of Latex Class Files**, v. 14, n. 8, 2015.

TEAM, G. B. **TensorFlow**. Disponível em: <<https://www.tensorflow.org/about/>>. Acesso em: 13 set. 2019.

TORO, V. DEL. **Fundamentos de Máquinas Elétricas**. 1a ed. Rio de Janeiro: LTC, 1999.

TRIANNI, A.; CAGNO, E.; ACCORDINI, D. A review of energy efficiency measures within electric motors systems. **Energy Procedia**, v. 158, p. 3346–3351, 2019.

TUREVSKIY, A. **PID Controller Design for a DC Motor**. Disponível em: <<https://www.mathworks.com/matlabcentral/fileexchange/26275-pid-controller-design-for-a-dc-motor>>. Acesso em: 13 set. 2019.

Referências

VERMEER, S. A. M. *et al.* Seeing the wood for the trees: How machine learning can help firms in identifying relevant electronic word-of-mouth in social media. **International Journal of Research in Marketing**, 2019.

WANG, D. *et al.* Detection of power grid disturbances and cyber-attacks based on machine learning. **Journal of Information Security and Applications**, v. 46, p. 42–52, 2019.

YUE, W. *et al.* Machine Learning with Applications in Breast Cancer Diagnosis and Prognosis. **Designs**, v. 2, n. 2, p. 13, 2018.

ZENG, N. *et al.* Deep Belief Networks for Quantitative Analysis of a Gold Immunochromatographic Strip. **Cognitive Computation**, v. 8, n. 4, p. 684–692, 2016.